

Die Varianz einer geometrischen Wartezeit

Wie eine potenziell unendliche Wartegeschichte
zu einer linearen Gleichung wird

Reimund Vehling

Ausgangspunkt

Bei unabhängigen Versuchen trete ein Treffer jeweils mit Wahrscheinlichkeit p auf, wobei $0 < p \leq 1$ gilt. Die Zufallsgröße T bezeichnet die Anzahl der Versuche bis zum ersten Treffer. Damit ist T geometrisch verteilt und nimmt die Werte $1, 2, 3, \dots$ an.

Erwartungswert und Varianz könnten unmittelbar aus der Verteilung

$$\mathbb{P}(T = n) = (1 - p)^{n-1}p, \quad n \geq 1,$$

durch unendliche Summen bestimmt werden. Hier soll jedoch nicht mit diesen Summen begonnen werden. Entscheidend ist vielmehr die Frage: *Was ist nach dem ersten Versuch geschehen?*

Wir setzen

$$q := 1 - p, \quad \mu := \mathbb{E}(T), \quad v := \mathbb{V}(T).$$

Nach einer Niete beginnt dieselbe Geschichte erneut

Sei T' eine neue, von der ersten Ziehung unabhängige Wartezeit mit derselben Verteilung wie T . Nach dem ersten Versuch gibt es genau zwei Möglichkeiten:

$$T = \begin{cases} 1, & \text{mit Wahrscheinlichkeit } p, \\ 1 + T', & \text{mit Wahrscheinlichkeit } q. \end{cases}$$

Im Trefferfall endet die Wartezeit nach einem Versuch. Im Nietenfall ist zwar ein Versuch vergangen, anschließend beginnt aber dieselbe Warteaufgabe erneut. In dieser Selbstähnlichkeit liegt der Kern der Herleitung.

Für den Erwartungswert folgt unmittelbar

$$\mu = p \cdot 1 + q(1 + \mu) = 1 + q\mu.$$

Somit gilt

$$p\mu = 1 \quad \implies \quad \mu = \frac{1}{p}.$$

Der Term $1 + q\mu$ erzählt bereits die ganze Geschichte: Ein Versuch findet auf jeden Fall statt; mit Wahrscheinlichkeit q beginnt danach dieselbe erwartete Wartezeit erneut.

Dieselben zwei Zweige erklären die Varianz

Auch für die Streuung betrachten wir nur die beiden Zweige nach dem ersten Versuch:

Erster Versuch	Wahrscheinlichkeit	Zweigmittelwert	Varianz im Zweig
Treffer	p	1	0
Niete	q	$1 + \mu$	v

Die Gesamtstreuung setzt sich aus zwei Anteilen zusammen.

- Im Nieten-Zweig tritt die ursprüngliche Varianz v erneut auf. Da dieser Zweig mit Wahrscheinlichkeit q erreicht wird, beträgt dieser Anteil qv .
- Die Zweigmittelwerte 1 und $1 + \mu$ liegen um μ auseinander. Die durch diese beiden unterschiedlichen Mittelwerte erzeugte Streuung beträgt $pq\mu^2$.

Der zweite Anteil lässt sich direkt aus der Definition der Varianz ablesen. Der Gesamtmittelwert liegt vom Zweigmittelwert 1 um $q\mu$ und vom Zweigmittelwert $1 + \mu$ um $p\mu$ entfernt. Daher gilt

$$p(q\mu)^2 + q(p\mu)^2 = pq(q + p)\mu^2 = pq\mu^2.$$

Damit entsteht die Varianzrekursion

$$v = \underbrace{qv}_{\substack{\text{dieselbe Streuung} \\ \text{beginnt erneut}}} + \underbrace{pq\mu^2}_{\substack{\text{Streuung zwischen} \\ \text{den beiden Zweigen}}}.$$

Im Term qv steckt die gesamte unendliche Fortsetzung. Eine potenziell unendliche Wartegeschichte wird zu einer linearen Gleichung, die anschließend nur noch umgeformt werden muss.

Die in der Rekursion verborgene unendliche Summe

Die Rekursion beseitigt die unendliche Summe nicht; sie bündelt sie. Setzt man $c := pq\mu^2$, so lautet die Gleichung $v = c + qv$. Wiederholtes Einsetzen macht die darin enthaltene geometrische Reihe sichtbar:

$$\begin{aligned} v &= c + qv \\ &= c + qc + q^2v \\ &= c + qc + q^2c + q^3v \\ &\vdots \\ &= c(1 + q + q^2 + \dots). \end{aligned}$$

Die direkte Umformung der linearen Gleichung summiert diese unendliche Reihe gleichsam auf einen Schlag:

$$v = c + qv \quad \implies \quad v = \frac{c}{1 - q}.$$

Da $1 - q = p$ und $c = pq\mu^2$ gilt, erhalten wir

$$v = q\mu^2.$$

Erst jetzt setzen wir $q = 1 - p$ und $\mu = 1/p$ ein. Damit folgt die Varianzformel

$$\boxed{\mathbb{V}(T) = \frac{1 - p}{p^2}}.$$

Was der Term erzählt

Die Formel kann auch in der Form

$$\mathbb{V}(T) = (1 - p) [\mathbb{E}(T)]^2$$

geschrieben werden. Daher gilt für die Standardabweichung

$$\boxed{\sigma(T) = \sqrt{1 - p} \mathbb{E}(T)}.$$

Jeder Faktor besitzt eine Bedeutung:

- $1 - p$ ist die Wahrscheinlichkeit, dass nach dem ersten Versuch dieselbe Wartegeschichte erneut beginnt.
- $1/p = \mathbb{E}(T)$ ist die Zeitskala dieser Geschichte.
- Für kleine Trefferwahrscheinlichkeiten liegt $\sqrt{1 - p}$ nahe bei 1. Die Wartezeiten streuen dann in derselben Größenordnung wie ihr Erwartungswert.

Die Formel steht am Ende. Vor ihr stehen die Frage, die Struktur und die Geschichte, aus der sie entsteht.