

Hol die OMA aus der Socke – Modell 4: Mit Zurücklegen

REIMUND VEHLING, HANNOVER

Modell 4: Passendes wird notiert und wieder zurückgelegt

In diesem Modell wird bei jedem Schritt ein Buchstabe aus $\{A, M, O\}$ gezogen und anschließend wieder zurückgelegt. Passt er zum nächsten benötigten Buchstaben, wird er notiert. Die Trefferwahrscheinlichkeit bleibt in jedem Zustand gleich $\frac{1}{3}$.

Simulation in GeoGebra

Modellspezifisch ist hier, dass aus einer erzeugten Zufallsliste zunächst die Position des ersten O , danach in der verbleibenden Teilliste die Position des ersten M und schließlich die Position des ersten A bestimmt wird. Die Summe dieser drei Wartezeiten ergibt die Realisation von T_4 .

Gerade diese Darstellung ist für den Einstieg hilfreich: Die Schülerinnen und Schüler können die erzeugte Liste selbst von links nach rechts durchgehen und händisch notieren, wann zuerst ein O , danach ein M und schließlich ein A auftritt. So bleibt sichtbar, wie aus einer einzelnen Zufallsfolge das Ergebnis eines Durchlaufs entsteht.

Damit wird zugleich ein grundlegender Unterschied zwischen GeoGebra und Python sichtbar. Python beschreibt den Prozess meist über Kontrollstrukturen wie `while`- oder `for`-Schleifen. GeoGebra arbeitet im hier gewählten elementaren Zugang dagegen mit erzeugten Objekten, insbesondere mit Listen und Teillisten. Die Listenlänge ist daher ein technischer Parameter der Simulation, nicht Bestandteil des mathematischen Modells.

```
Socke = {"A", "M", "O"}
n = 200
z1 = Stichprobe(Socke, n, true)
PosO = IndexVon("O", z1)
z2 = Teilliste(z1, PosO + 1, Länge(z1))
PosM = IndexVon("M", z2)
z3 = Teilliste(z2, PosM + 1, Länge(z2))
PosA = IndexVon("A", z3)
Wartezeit = PosO + PosM + PosA
```

Listing 1: GeoGebra-Befehle für einen Durchlauf von Modell 4

Statt einer einzigen langen Ziehungsliste könnte man auch drei getrennte Ziehungslisten verwenden; Teillisten wären dann nicht nötig. Damit würde jedoch die spätere Zerlegung in drei unabhängige Warteabschnitte bereits in der Simulation vorweggenommen. Die

gemeinsame Liste lässt dagegen sichtbar werden, wie die drei Abschnitte nacheinander aus einer einzigen Zufallsfolge entstehen.

Streng genommen liefert der Durchlauf nur dann eine Wartezeit, wenn OMA innerhalb der n erzeugten Ziehungen vollständig wird. Für $n = 200$ ist die Gegenwahrscheinlichkeit allerdings verschwindend klein. Für $p = \frac{1}{3}$ beträgt sie sogar nur

$$\mathbb{P}(T_4 > 200) \approx 3,1 \cdot 10^{-32}.$$

Herleitung der Verteilung

Damit OMA genau bei der n -ten Ziehung vollständig ist, muss die letzte Ziehung ein Treffer sein. In den ersten $n - 1$ Ziehungen müssen genau zwei Treffer und $n - 3$ Nieten liegen. Daher gilt im ursprünglichen Modell für $n \geq 3$:

$$\mathbb{P}(T_4 = n) = \binom{n-1}{2} \left(\frac{1}{3}\right)^3 \left(\frac{2}{3}\right)^{n-3}.$$

Entscheidend ist hier die konstante Trefferwahrscheinlichkeit.

Allgemeiner kann man diese konstante Trefferwahrscheinlichkeit mit p bezeichnen. Dabei bedeutet Treffer jeweils: Der gezogene Buchstabe ist der nächste benötigte Buchstabe. Im ursprünglichen Modell mit den drei gleichwahrscheinlichen Buchstaben O, M, A gilt $p = \frac{1}{3}$. Für $0 < p < 1$ erhält man

$$\mathbb{P}_p(T_4 = n) = \binom{n-1}{2} p^3 (1-p)^{n-3}, \quad n \geq 3.$$

Wie bei den anderen Modellierungen ist der Einsatz von Baumdiagrammen nicht zielführend. Eine entscheidende Hilfe liefern hier Zustandsgraphen (siehe Abb. 1) mit jeweils vier Zuständen S, O, OM, OMA .




Abb. 1: Zustandsgraph für Modell 4

In jedem der ersten drei Zustände führt ein Treffer mit Wahrscheinlichkeit $\frac{1}{3}$ einen Zustand weiter; mit Wahrscheinlichkeit $\frac{2}{3}$ bleibt man im aktuellen Zustand.

Alternative Sichtweise: Verteilung der Nieten

Eine zweite Möglichkeit besteht darin, die $n-3$ Nieten auf die drei Warteabschnitte zu verteilen:

$$\underbrace{\text{Nieten vor } O}_{x_1} \quad \underbrace{\text{Nieten vor } M}_{x_2} \quad \underbrace{\text{Nieten vor } A}_{x_3}$$

Dann gilt $x_1 + x_2 + x_3 = n - 3$. Die Anzahl der nichtnegativen ganzzahligen Lösungen ist

$$\binom{n-1}{2}.$$

Der Zusammenhang kommt aus dem Stars-and-Bars-Prinzip: Man verteilt $n-3$ ununterscheidbare Nieten auf 3 Warteabschnitte. Dafür braucht man 2 Trennstiche, also insgesamt $n-3+2=n-1$ Positionen. Man wählt aus diesen $n-1$ Positionen die 2 Trennstiche. Dafür gibt es $\binom{n-1}{2}$ Möglichkeiten. Damit ergibt sich dieselbe Formel. Diese Methode ist mathematisch elegant, für Schülerinnen und Schüler aber ungewohnter; sie eignet sich daher eher als zweite Lösungsmöglichkeit oder als Ausblick.

Insgesamt ist die Herleitung der Formel eine schöne Anwendung des Binomialkoeffizienten. Es handelt sich allerdings nicht um eine Binomialverteilung der Zufallsgröße T_4 , sondern um eine Wartezeitverteilung. Der Binomialkoeffizient zählt hier die möglichen Positionen der ersten beiden Treffer.

Für $p = \frac{1}{3}$ steigen die Einzelwahrscheinlichkeiten zunächst an und fallen anschließend langsam ab. Der lange rechte Rand erklärt, warum einzelne Simulationen deutlich vom Erwartungswert abweichen können.

Kenngrößen in GeoGebra-CAS

Die Frage nach der mittleren Wartezeit führt auch hier direkt zum Erwartungswert $\mathbb{E}(T_4)$. Die Simulationen lassen schon vermuten, dass im ursprünglichen Sockenmodell $\mathbb{E}(T_4) = 9$ gilt: Da die Trefferwahrscheinlichkeit für jeden der drei benötigten Buchstaben $p = \frac{1}{3}$ beträgt, erwartet man bis zum ersten Auftreten des jeweils passenden Buchstabens drei Ziehungen, insgesamt also 9.

Noch aufschlussreicher ist aber die allgemeine Rechnung mit einer konstanten Trefferwahrscheinlichkeit p . Sie macht sichtbar, welche Struktur hinter den Zahlen steckt:

$$\mathbb{E}_p(T_4) = \sum_{n=3}^{\infty} n \cdot \mathbb{P}_p(T_4 = n) = \frac{3}{p}.$$

Das Ergebnis passt zur anschaulichen Deutung: Die Wartezeit besteht aus drei gleichartigen Warteabschnitten, und jeder dieser Abschnitte hat die mittlere Länge $\frac{1}{p}$.

Die Simulationen zeigen zugleich eine deutliche Streuung. Daher liegt es nahe, neben dem Erwartungswert auch die Varianz zu bestimmen. Die nicht zu unterschätzende Leistung der Lernenden ist dabei die Aufstellung der Varianzformel. GeoGebra-CAS liefert dann

$$\mathbb{V}_p(T_4) = \sum_{n=3}^{\infty} \left(n - \frac{3}{p}\right)^2 \cdot \mathbb{P}_p(T_4 = n) = \frac{3(1-p)}{p^2}.$$

Für das ursprüngliche Modell gilt $p = \frac{1}{3}$. Damit ergeben sich $\mathbb{E}_{1/3}(T_4) = 9$ und $\mathbb{V}_{1/3}(T_4) = 18$.

Listing 2 zeigt die Umsetzung mit GeoGebra im CAS-Fenster. Es ist auch aufschlussreich, zunächst endliche Summen bis zur oberen Grenze N zu betrachten und anschließend den Grenzübergang $N \rightarrow \infty$ vorzunehmen.

```
f(n,p):=nCr(n-1,2)*p^3*(1-p)^(n-3)
E(p):=Summe(n*f(n,p),n,3,inf)
V(p):=Summe((n-E(p))^2*f(n,p),n,3,inf)
E(1/3)
V(1/3)
```

Listing 2: Erwartungswert und Varianz mit GeoGebra-CAS, allgemein und für den Fall $p = \frac{1}{3}$

Abbildung 2 zeigt den Vergleich zwischen den simulierten Daten und den exakten Modellwahrscheinlichkeiten.




Abb. 2: Vergleich der mit Python simulierten und der exakten Verteilung für Modell 4 bei $N = 10\,000$ Wiederholungen.

Die relativen Häufigkeiten $H(T_4 = n)$ entstehen aus der Simulation (graue Säulen); die Werte $\mathbb{P}(T_4 = n)$ ergeben sich aus dem zuvor entwickelten Modell (schwarze Punkte). Damit werden zwei Ebenen bewusst nebeneinandergestellt: Die Simulation erzeugt Daten, das Modell liefert Wahrscheinlichkeiten. Die

als senkrechte Intervalle eingezeichneten 95%-Wilson-Konfidenzintervalle machen sichtbar, welche Abweichungen bei einer Stichprobe dieser Größe noch als erwartbare Zufallsschwankungen angesehen werden können.

Es wurden $N = 10\,000$ Durchläufe simuliert. Auf zwei Nachkommastellen gerundet ergeben sich die Schätzwerte $\widehat{\mathbb{E}}(T_4) = 8,98$ und $\widehat{\mathbb{V}}(T_4) = 18,01$. Die Simulation ist im zugehörigen Python-Notebook reproduzierbar dokumentiert.

Strukturblick: drei gleiche Warteabschnitte

Die Formeln für Erwartungswert und Varianz lassen sich auch ohne CAS inhaltlich verstehen. Die Wartezeit T_4 setzt sich aus drei Wartezeiten zusammen:

$$T_4 = X_1 + X_2 + X_3.$$

Dabei beschreibt X_i die Anzahl der Ziehungen im i -ten Warteabschnitt, also vom Beginn beziehungsweise vom vorherigen Treffer bis zum nächsten Treffer. In jedem Abschnitt bleibt die Trefferwahrscheinlichkeit gleich p .

Für eine solche Wartezeit gilt

$$\mathbb{E}(X_i) = \frac{1}{p} \quad \text{und} \quad \mathbb{V}(X_i) = \frac{1-p}{p^2}.$$

Da die drei Warteabschnitte unabhängig und gleich verteilt sind, folgt

$$\mathbb{E}(T_4) = \mathbb{E}(X_1) + \mathbb{E}(X_2) + \mathbb{E}(X_3) = \frac{3}{p}$$

und

$$\mathbb{V}(T_4) = \mathbb{V}(X_1) + \mathbb{V}(X_2) + \mathbb{V}(X_3) = \frac{3(1-p)}{p^2}.$$

Der Erwartungswert wächst wie $\frac{1}{p}$, die Varianz wächst für kleine p wie $1/p^2$. Für die Standardabweichung gilt hingegen

$$\sigma_p(T_4) = \sqrt{\frac{1-p}{3}} \cdot \mathbb{E}_p(T_4)$$

Erwartungswert und Standardabweichung wachsen somit für kleine p beide in der Größenordnung $1/p$. Aus dieser Sicht ist T_4 die Wartezeit bis zum dritten Treffer bei konstanter Trefferwahrscheinlichkeit p . In der Fachsprache wird diese Wartezeit durch eine negative Binomialverteilung beschrieben.

Tür zur Uni: die Faltungsidee

Aus derselben Zerlegung lässt sich auch die Verteilung von T_4 durch Faltung gewinnen. Setze zunächst

$$S_2 = X_1 + X_2$$

Dann entspricht S_2 der Anzahl der Versuche, bis insgesamt $r = 2$ Treffer erzielt wurden. Dabei sei

$$\mathbb{P}(X_i = k) = (1-p)^{k-1}p, \quad k = 1, 2, \dots$$

Die Zufallsgröße X_i beschreibt also die Anzahl der Versuche bis zum nächsten Treffer.

Die Grundidee der Faltung lautet: Will man die Verteilung einer Summe bestimmen, so summiert man über alle möglichen Zerlegungen des Summenwertes. Für $S_2 = X_1 + X_2$ ergibt sich daher

$$\begin{aligned} \mathbb{P}(S_2 = n) &= \sum_{k=1}^{n-1} \mathbb{P}(X_1 = k) \mathbb{P}(X_2 = n-k) \\ &= \sum_{k=1}^{n-1} p(1-p)^{k-1} p(1-p)^{n-k-1} \\ &= (n-1)p^2(1-p)^{n-2}, \quad n \geq 2. \end{aligned}$$

Für die Summe aus drei Wartezeiten wird anschließend erneut gefaltet:

$$\begin{aligned} \mathbb{P}(T_4 = n) &= \sum_{s=2}^{n-1} \mathbb{P}(S_2 = s) \mathbb{P}(X_3 = n-s) \\ &= \sum_{s=2}^{n-1} (s-1)p^2(1-p)^{s-2} \cdot p(1-p)^{n-s-1}. \end{aligned}$$

Zusammenfassen und faktorisieren liefert schließlich

$$\begin{aligned} \mathbb{P}(T_4 = n) &= p^3(1-p)^{n-3} \sum_{s=2}^{n-1} (s-1) \\ &= p^3(1-p)^{n-3} \frac{(n-1)(n-2)}{2} \\ &= \binom{n-1}{2} p^3(1-p)^{n-3}, \quad n = 3, 4, \dots \end{aligned}$$

Damit ist T_4 die Anzahl der Versuche bis zum dritten Treffer. Unter der hier verwendeten Zählweise – Anzahl der Versuche bis zum dritten Treffer – gilt

$$T_4 \sim \text{NegBin}(r = 3, p).$$

Reflexion der Modellannahme

Die einfache Form der Verteilung beruht wesentlich darauf, dass der Inhalt der Socke unverändert bleibt. Nach jeder Ziehung liegt wieder dieselbe Situation vor; die Trefferwahrscheinlichkeit für den jeweils nächsten benötigten Buchstaben beträgt stets $\frac{1}{3}$. Vor dem ersten Erfolg ist ein *O* ein Treffer, danach ein *M*, danach ein *A*. Der Begriff Treffer bezieht sich also jeweils auf den nächsten benötigten Buchstaben. Dadurch lässt sich die Wartezeit als Summe von drei gleich verteilten Wartezeiten auffassen.

Anschrift des Verfassers:

Reimund Vehling
vehling@icloud.com